國立中央大學

AI 校園韌性與智慧事件決策系統

完整系統規劃書

NCU Resilience AI

需求基線　功能規格　AI Skills　資料架構　API　開發與驗證

文件版本：1.0 ｜ 日期：2026 年 10 月 16 日

文件性質：開發規劃基線／專題實作依據／未來導入參考

文件說明與決策紀錄

本文件依據需求確認整理，目標是先完成可展示的研究專題，再保留未來於中央大學正式導入的可能性。規劃內容為系統設計，不代表已獲得校方授權、社群資料存取許可，或已完成上線。

需求項目	已確認決策
開發目的	專題成果與未來正式導入並重
使用者	公開介面供一般使用者；後台目前僅開發團隊管理
資料來源	校內公告、社群、新聞、完全匿名的自主通報
分析深度	事件分類、證據核驗、跨事件關聯、趨勢預警、What-if 模擬
通知政策	AI 判為高風險即啓動自動對外警示；對外內容採公共安全提醒規則控管
模型	優先 OpenAI 雲端 API；保留供應商替換能力
進度	無硬性期限，分階段完成完整功能
交付	正式 PDF 系統規劃書

需要正視的設計衝突

「AI 認為高風險就立即公開」與「匿名投稿、未核實社群內容」同時存在時，可能造成虛假指控、個資外洩、誹謗或恐慌。產品採雙軌：高風險立即自動觸發公開的中性安全提醒（若通過敏感內容及來源規則）；未核實的人物／單位指控不得自動公開，並同時進行內部升級。系統不得宣稱未經查證的犯罪或責任歸屬。這是為保有自動發布功能而加入的必要防護規格。

1. 專案背景、目標與範圍

1.1 核心問題

校園公共資訊分散在學校處室公告、社群平台、媒體新聞與個人通報中；各來源格式不同、時間不同，事件容易重複、延遲發現或缺乏後續追蹤。單純的輿情彙整不能回應「何時應處置、如何處置、是否改善」三項問題。

1.2 系統目標

- 統一取得有權處理的公開公告、新聞及自主通報。
- 將文字轉為可查證的事件，保存證據與來源。
- 自動評估事件風險並觸發分級警示。
- 提供根因假設、可操作的改善措施和成本／影響比較。
- 持續追蹤處理進度與校園韌性指標。
- 保留可攜式 AI Skills，降低單一模型供應商依賴。

1.3 範圍與非目標

本系統是校園資訊與決策支援平台，不取代校安中心、消防、警政或醫療等正式緊急通報管道；不替校方作出法律認定、行政處分或個人責任歸屬；不把模型生成的模擬效果視為實際因果證據。

2. 使用者、權限與產品情境

角色	可使用功能	限制
訪客	查詢公開事件、校園公告、已發布安全提醒與改善進度	不可讀取原始匿名投稿者資訊與內部風險紀錄
匿名投稿者	送出通報、取得隨機查詢碼、補充資訊（若持有查詢碼）	無權建立已核實事件、不得直接觸發指控公開
開發團隊管理者	管理來源、查證、風險重算、撤回公告、追蹤改善、檢視稽核紀錄	以個人帳號與 RBAC 控制；敏感存取可稽核
系統服務帳號	執行排程、AI、通知	最小權限、金鑰輪替

2.1 關鍵使用情境

- 社群提及疑似自行車失竊：萃取地點與時間、辨識重複轉載、保留未核實狀態；評估財物風險，發布泛化防竊提醒並提示待查證。
- 宿舍停電公告：從官方來源建事件，整合修復時程與公共提醒，後續追蹤恢復時間。
- 匿名通報食安疑慮：限制公開個人／店家指控，先內部確認；可發布中性就醫或保存證據提醒。
- 相同校園區域多次出現事件：以時間、地點與分類連結，產生跨事件分析與假設，而非直接認定因果。

3. 系統整體架構

建議架構：React + TypeScript 前端、Python FastAPI 模組化單體後端、PostgreSQL / pgvector、Redis + Celery Worker、物件儲存（僅經授權附件）、OpenAI API Adapter、風險規則引擎。第一階段用 Docker Compose；正式部署再加負載均衡、儲存備份、監控與金鑰管理。

層級	元件	責任
呈現層	Public Web / Admin Web	公開查詢、管理後台、通報與通知訂閱
API 層	FastAPI + RBAC	驗證、事件查詢、管理操作、限流
收集層	Source Adapters / Scheduler	官方公告、授權社群、RSS、匿名通報
資料層	PostgreSQL + pgvector + Object Store	原文版本、事件、向量、附件、稽核
AI 層	Skill Registry + Runner + LLM Adapter	技能載入、提示模板、JSON 驗證、輸出紀錄
決策層	Risk / Evidence / Publishing Rules	計分、警報門檻、公開內容安全規則
工作層	Celery + Redis	擷取、分析、通知、重試與死信處理

層級	元件	責任
維運層	Logs / Metrics / Backup / CI	可觀測性、安全、復原

3.1 端到端資料流程

來源擷取 → 原始資料保存 → 清洗與版本 → 與校園相關性篩選 → 事件抽取 → 同事件合併 → 查證狀態 → 風險評估 → 規則引擎 → 公開提醒／內部通知 → 改善追蹤 → 重新評估與歸檔。所有 AI 結果都附上 schema_version、model_id、skill_version、source_evidence_ids 和時間戳記。

4. 主要功能需求（F01–F10）

F01 多來源資訊採集

功能：來源 Adapter、定時擷取、授權與配額資訊、失敗重試、來源健康狀態

驗收：同來源增量取得且記錄失敗；重試不重複寫入

F02 標準化與來源追溯

功能：時間標準化、來源版本、內容雜湊、語系、去重、來源 URL

驗收：任一事件可以反查原始文章／擷取時間

F03 AI 事件管理

功能：事件萃取、分類、類似事件合併、手動拆分與合併

驗收：同一事件跨文章歸併，人工可回滾

F04 多維風險評估

功能：五維評分、閾值、critical_override、歷史版本

驗收：相同輸入版本產生可重現決策與理由

F05 自動預警中心

功能：高風險即時觸發、公開提醒策略、去重、撤回與更正

驗收：未核實指控不得對外以事實發布

F06 決策輔助

功能：根因假設、缺失證據、短中長期方案與責任建議

驗收：方案必須區分已證實與待查證原因

F07 儀表板

功能：事件搜尋、時序趨勢、分類統計、公開與內部視圖

驗收：角色視圖資料隔離、統計可追溯

F08 跨事件關聯

功能：語意＋時間＋地點關聯、人工確認、關聯圖

驗收：同事件與相關事件分開表示

F09 What-if 情境模擬

功能：基準值、假設改善率、成本、敏感度、結果版本

驗收：不得顯示成真實政策成效預測

F10 改善與韌性追蹤

功能：負責人、狀態、期限、成效比較、韌性指標

驗收：完整記錄發現→處理→恢復→改進

5. 可攜式 AI Skills 設計

採 Agent Skills 開放格式：每個 Skill 有符合規格的 SKILL.md（YAML frontmatter）、rules、schemas、references、scripts 與 tests。執行端由自建 Skill Runner 發現、載入並驗證輸出；可以移交給支援 Agent Skills 的其他 AI 客戶端，惟工具權限與 API Adapter 仍需按平台調整。

Skill ID	技能名稱	輸入／產出
S01	relevance-filter	文章→校園相關性與判斷理由
S02	event-extractor	文章→事件、時間、地點及證據位置
S03	event-classifier	事件→類別、標籤及分類依據
S04	event-linker	候選事件→同事件／關聯事件及信心
S05	evidence-verifier	多來源證據→confirmed/unverified/disputed/false
S06	risk-assessor	證據與事件→五維風險及不確定性
S07	root-cause-analyst	已知事實→假設、待查資訊與支持證據
S08	solution-planner	事件評估→學生／校方措施與優先級
S09	trend-forecaster	時序統計→異常解釋及前瞻訊號
S10	scenario-simulator	政策參數→模擬假設與解釋

5.1 Skill 封裝與跨 AI 共用

```
campus-risk-assessor/
SKILL.md
schemas/risk-output.schema.json
scripts/calculate_risk.py
references/risk-policy.md
tests/cases.json
```

SKILL.md 必須有 name 和 description 的 YAML frontmatter；規則描述何時啓動、證據優先序、輸入輸出、不可做事項及 Fallback。所有 Skills 需提供 JSON Schema 與 golden tests，輸出不得直接繞過後端業務規則進入公開管道。

5.2 執行治理

- LLM 內容視為不可信輸入；隔離提示注入，禁止來源文章修改系統規則。
- 限制單次模型呼叫費用與併發，使用快取、重試與逾時。
- 驗證 JSON、列舉值、數值範圍、證據 ID 存在性及 PII 安全。
- 保留 Prompt／Skill／模型版本與批次 ID，支援 regression tests。
- 無足夠證據時允許 abstain，不强迫模型給根因或真偽結論。

6. 風險模型、證據查證與發布政策

6.1 初始五維風險模型

Risk = 0.30 × 人身安全 + 0.20 × 營運 + 0.15 × 財產 + 0.15 × 聲譽 + 0.20 × 影響範圍；各面向 0—100。建議初始分級：低 0—29、中 30—59、高 60—79、極高 80—100。權重是試行假設，非經驗校正結果。已確認重大人身危害走 critical_override，不受加權平均稀釋。

6.2 獨立三種判斷

欄位	意義	注意
classification_confidence	AI 判斷事件類別的把握程度	不等於事件真實性
verification_status	證據是否足以支持事件事實	由可追溯規則／人工查證更新
risk_score	若事件成立，可能造成的影響	需附不確定性與評分依據

6.3 事件與警示生命週期

事件：detected → analyzing → unverified → verified / disputed / false → monitoring / resolved / archived。警示：candidate → policy_checked → eligible → published → updated / retracted / expired。發布動作使用 idempotency_key；支援停止發送、改版、回收與正確性說明。

6.4 自動公開高風險事件策略

情境	自動對外處理
已核實且具公共安全必要性的事件	公開經 PII 處理的事實與防護建議
高風險但僅匿名單一來源	立即觸發「一般性安全提醒」或內部警報；不公開未證實具體指控
涉及可識別個人、店家或教職員的指控	預設阻擋具體指控，要求核驗／人工作業
來源互相矛盾或可能是惡作劇	內部升級查證，不主張事件已發生
官方緊急公告	依官方內容快速發布，標記來源與更新時間

這是滿足「高風險自動發布」需求的必要實作邊界：系統會自動對外發布允許的安全性訊息，但不允許將未核實指控升格為事實。另須制定爭議處理聯絡管道、回收 SLA 與錯誤通知機制。

7. 匿名自主通報與平台防護

- 提交時不要求姓名或帳號，產生高熵亂數 receipt_token 用於私下查詢／補充。
- 採 IP 等短期防濫用控制時必須揭露用途、保留期限及權限，避免默默宣稱完全無可識別資訊。
- CAPTCHA、速率限制、附件類型白名單、惡意檔案檢測、同文大量投稿偵測。
- 避免顯示原始匿名投稿全文；自動去除個資與敏感位置。
- 資料保留與刪除請求流程依部署前法遵審查設定；附件與原文加密儲存。
- 緊急通報頁面明確說明此系統非 110／119 或校安緊急聯絡管道替代品。

8. 事件關聯、趨勢與 What-if

8.1 關聯分類

same_event：不同文章報導同一件事；related_event：在時間／地點／類型上相關但不保證相同；hypothesized_cause：需要進一步驗證的潛在因素。邊要存 evidence_ids、方法、分數、人工決策與更新時間。

8.2 趨勢預警

以週／月事件頻率及地點分布建立基準；早期使用移動平均、EWMA 或 Poisson 變化偵測。評估時使用時間序列回測，並將資料來源數量、學期與假期、通報習慣變化納入解讀。避免把社群聲量等同真實事件數。

8.3 情境模擬

第一版用透明規則：baseline × Π(1 − assumed_effect_i)。輸入包含基準量、方案列表、措施成本、效果假設區間、時間窗、地點。輸出包含假設情境、敏感度、成本分級、適用限制。若日後有足夠真實資料，再考慮控制變因與對照組估計。

9. 資料庫與核心欄位規格

表	核心欄位	重要約束／索引
sources	id, name, type, access_policy, enabled, poll_interval	唯一來源代碼
ingestion_runs	id, source_id, started_at, finished_at, status, counts	來源＋執行時間
source_items	id, source_id, external_id, url, published_at, fetched_at	unique(source_id,external_id) 可空替代
source_item_versions	id, item_id, content_hash, normalized_text, captured_at	unique(item_id,content_hash)
events	id, title, type, location_id, status, created_at	type/status/time indexes
event_evidence	event_id, source_item_id, support_type, excerpt	compound PK
event_relations	id, from_id, to_id, type, score, evidence	禁止 self-loop
risk_assessments	id, event_id, dimensions, score, policy_version	每次評分保留歷史
ai_analysis_runs	id, event_id, skill_name, skill_version, model_id, result	schema_version, trace_id
alerts	id, event_id, audience, state, version, body	unique(idempotency_key)
alert_deliveries	id, alert_id, channel, destination, status	unique(alert_id,channel,destination,version)
reports	id, receipt_hash, text_encrypted, status, created_at	匿名、限流、存取控制
locations	id, name, lat, lng, precision	位置不明可 null
response_actions	id, event_id, owner, due_at, state, proof	狀態變更歷史
scenario_runs	id, event_id, input, output, engine_version	可重現的版本與隨機種子
audit_logs	id, actor, action, target, timestamp, metadata	append-only

9.1 重要關係與一致性

一個 Source 對多篇 Source Item；Source Item 可有多版本；Events 與 Source Items 以 event_evidence 多對多連接；Event 對多次風險分析、多則警示、多項改善措施及情境模擬。使用 PostgreSQL 交易確保匯入去重與 provenance 儲存原子性。原始內容與公開摘要分表或分欄保護。

9.2 事件抽取輸出 Schema（摘要）

```
{ event_type, title, occurrence_time, location,
verification_status, evidence_ids[],
classification_confidence, risk_dimensions{},
possible_causes[], recommendations[],
publication_eligibility, schema_version }
```

10. API 與權限規格

方法	路由	用途／權限
GET	/api/v1/events	僅公開事件與欄位
GET	/api/v1/events/{id}	公開事件詳細頁、來源
GET	/api/v1/alerts	公開的有效警示
POST	/api/v1/reports	匿名投稿，回傳收據碼；限流
POST	/api/v1/reports/{token}/followups	持有效通報收據補件
GET	/api/v1/dashboard/summary	公開聚合統計
GET	/api/v1/admin/events	管理者全部事件
POST	/api/v1/admin/events/{id}/verify	管理者查證結果
POST	/api/v1/admin/events/{id}/analyze	重跑分析，記錄版本
POST	/api/v1/admin/alerts/{id}/retract	管理者撤回及原因
POST	/api/v1/admin/scenarios	管理者建立模擬
GET	/api/v1/admin/ingestion-runs	檢視來源執行記錄
GET	/api/v1/admin/audit-logs	管理者稽核查詢

10.1 標準 API 行為

統一 {data,meta,error} 回應結構；採 cursor 分頁；錯誤碼至少含 VALIDATION_ERROR、UNAUTHORIZED、FORBIDDEN、NOT_FOUND、RATE_LIMITED、CONFLICT、MODEL_UNAVAILABLE。管理者採 HttpOnly Secure Cookie 或安全 Token 配置、CSRF 防護及操作審計。所有寫入建立 request_id；高風險發送使用冪等鍵。

11. 前端頁面與互動規格

介面	頁面	關鍵元素
公開	首頁	校園動態摘要、最新警示、來源更新時間
公開	事件列表／詳細	搜尋、篩選、查證狀態、已核實來源、改善資訊
公開	通報頁	匿名表單、緊急提示、收據碼、上傳保護
公開	公開報告	趨勢、事件類型、總結及方法限制
管理	事件工作台	來源對照、風險分項、證據清單、更新歷史
管理	警示中心	自動發布紀錄、規則阻擋、撤回、更正
管理	Skills 管理	技能版本、模型成本、失敗率、測試結果
管理	關聯與模擬	事件關聯圖、方案參數、敏感度輸出
管理	維運與稽核	來源健康、失敗重試、RBAC、審計

12. 非功能需求與安全治理

項目	初始目標
可用性	公開端目標 99.5% 月可用性（正式部署時再確認）
效能	公開事件列表 p95 < 1.5 秒（在明確測試環境與負載下）
排程	可用來源擷取成功率　　98%；來源失敗可重跑
可靠性	佇列失敗重試、死信處理、警報冪等、每日備份
權限	公開／管理資料隔離、最小權限、登入安全
隱私	資料最小化、脫敏、保留期限與刪除流程
觀測	任務成功率、AI 延遲與費用、通知失敗率、trace id
模型治理	Prompt／Skill 版本化、輸入防注入、schema 驗證
可攜性	Agent Skills 格式、模型 Adapter、無廠商特定核心業務邏輯

13. 分階段開發計畫

階段	主要工作	交付／驗收
P0 基線	規格、來源授權盤點、CI、Docker、DB migration、權限規格	乾淨環境可重建；migration up/down 及 CI 通過
P1 採集	公告來源 Adapter、RSS、資料標準化、增量、去重	至少三個合法來源；七天穩定擷取；重跑零重複
P2 AI	S01–S08、結構化輸出、查證狀態、風險引擎	標記測試集、可回溯來源、無證據 abstain
P3 產品	公開端／後台、匿名通報、規則式自動警報	RBAC、安全發布、撤回、更正、端到端測試
P4 關聯	跨事件圖、時序統計、韌性追蹤	人工評估關聯、歷史回測無未來資料
P5 模擬	S09–S10、政策情境與敏感度、部署維運	固定輸入重現結果、備份與復原演練

因無固定截止日期，採品質閘門（exit criteria）而非時間驅動推進。可參考 15—22 週為初步規劃區間，但依資料授權、標記資料與迭代幅度可能延長。

13.1 建議最小可展示端到端版本

來源公告 → PostgreSQL 版本儲存 → AI 事件分析 → 風險評估 → 公開安全提醒資格判定 → 管理儀表板／公開事件頁，並有完整稽核與重跑能力。社群平台取得權限不應阻塞這條路徑。

14. 測試策略與驗證指標

類別	驗證方式	初始門檻
採集	連續七天來源執行、重跑及來源更新測試	成功率 98%，去重無重複寫入
分類	人工標記測試集 Macro-F1	0.85
同事件合併	以事件分組切分的 Precision / Recall	Precision 0.95、Recall 0.85
高風險召回	人工標記高風險案例	Recall 0.95
結構化輸出	Schema 驗證與失敗重試	99% 合格
來源追溯	AI 事實性結論對應 evidence_ids	100% 可追溯或明確 abstain
自動發布	惡意投稿、誤報、個資、虛構事件對抗測試	未核實具體指控錯誤公開：0
通知	重試、冪等與撤回測試	相同警報版本無重複外送
效能	負載測試公開端查詢 p95	< 1.5 秒（定義測試負載）
模擬	相同參數／版本／隨機種子再跑	數值可重現
復原	還原備份與錯誤情境演練	可完成完整復原

14.1 測試資料策略

建立至少 300—500 筆人工標記樣本：正常公告、真實事件、謠言、相似但不同事件、跨站轉載、時間地點模糊、來源衝突與匿名惡意投稿。採事件／時間切分，避免同一事件轉載同時進入開發與測試集合。對外發布安全性採嚴格阻擋測試。

14.2 各階段驗收紀錄模板

每一個 PR 或階段輸出：Git commit、功能清單、測試命令、pass/fail、資料庫 migration 結果、API 範例、已知限制、安全檢查與必要回退步驟。高風險功能需另附人工審核的測試案例。

15. 校園韌性指標與治理績效

初期韌性指數：CRI = 0.25 Detection + 0.25 Response + 0.25 Recovery + 0.25 Adaptation，各構面標準化 0—100。實務指標可採「發現延遲」「通報處置延遲」「服務恢復時間」「重複事件比例／改善完成率」。資料不足時直接顯示 N/A，不做假精確評分。

必須區分事件實際頻率與通報頻率：若宣導後通報增加，不代表校園風險一定增加。公開報表應呈現資料覆蓋率、統計時間窗、樣本量與來源限制。

16. 風險登錄與緩解措施

風險	嚴重性	對策
社群資料無合法機器存取管道	高	Adapter 可拔插、官方授權優先、人工匯入備援
匿名惡意通報與公開誤報	極高	速率限制、敏感內容政策、查證狀態、可撤回
模型幻覺或將相關當因果	高	Evidence IDs、abstain、分類與真實性分離
PII、附件與原文外洩	極高	加密、隔離、最小化、審計、刪除流程
模型成本與延遲上升	中	分級模型、快取、批次、成本上限與降級
來源站版型改版	中	Adapter 健康檢測、抽取測試與人工告警
缺少真實資料驗證 What-if	高	先標為假設情境，提供敏感度及限制說明
只有開發團隊管理無校方窗口	中	避免冒稱官方，加入非官方免責說明及未來移交流程

17. 技術決策與未來轉正式導入

初期不採微服務，因團隊需要先驗證資料品質、工作流程與 Skills 可靠性。後續使用者成長、正式校方合作時再拆分 ingestion、AI jobs、alerting 等需要獨立擴容的服務。後台先只供開發團隊使用；如進入正式校園流程，需加入校方窗口、服務分工、法遵審查、發布權責、申訴及資料治理協議。

17.1 最優先的施工順序

- 先建立授權來源清單、事件欄位與狀態模型。

- 完成 migration、adapter、冪等寫入與來源追溯。
- 接入 OpenAI API Adapter 與可攜式 Skills Runner。
- 建立評測資料與安全發布規則，再開放自動公開提醒。
- 完成雙介面與匿名通報，之後擴充關聯、趨勢、What-if。

18. 參考資料與規格

Agent Skills specification：https://agentskills.io/specification
OpenAI API Skills：https://developers.openai.com/api/docs/guides/tools-skills
Dcard 用戶使用協議：https://www.dcard.tw/terms
Meta Graph API 文件：https://developers.facebook.com/docs/graph-api/
全國法規資料庫（個人資料保護法）：https://law.moj.gov.tw/
備註：平台權限、政策與法律要求可能修訂。正式部署前應重新確認當時生效的條款與取得資料的合法依據。本文件不構成法律意見。

附錄 A：首批測試案例

案例	預期結果
A01 官方施工公告	建立已核實事件；分類校園營運；可公開來源
A02 社群單篇失竊指控	未核實；可產生中性防竊提醒，不公開個人指控
A03 三則相同失竊新聞轉載	事件數 1、來源證據數 3
A04 兩起不同日失竊	建立不同事件，另可建立 related_event 關聯
A05 匿名惡意誣指個人	阻擋對外指控；管理端標記異常
A06 官方宣布事件澄清	更新事件查證狀態，必要時自動更正／撤回
A07 重送相同任務	原文、事件與提醒符合冪等要求
A08 模型輸出無 evidence_ids	不得將主張標記 verified
A09 What-if 效果值全為未知	顯示無法估計，而非自造百分比
A10 儲存中斷或通知失敗	回復／重試，不產生不一致的重複發布

附錄 B：專案組織結構建議

```
frontend/ public/ admin/ components/ api/
backend/ app/api/ app/models/ app/ingestion/
app/ai/ app/risk/ app/alerts/ app/simulations/
skills/ relevance-filter/ event-extractor/ ...
tests/ unit/ integration/ e2e/ golden/ security/
docs/ requirements/ architecture/ api/ governance/
infra/ docker/ migrations/ monitoring/
```

完。此版本是可作為系統實作基線的完整規劃書；隨技術驗證成果，建議以 v1.1、v1.2 增修資料來源授權、schema、門檻與部署規格。